Detectarea textelor umane și generate de AI

Tema 6 - Decision model cu Unsloth

1. Obiectiv și date

Am adaptat notebookul Unsloth pentru o decizie binară: un text de știre în limba română este clasificat ca human sau ai. Modelul ales este Qwen3.5-4B, ajustat cu LoRA și componenta de decizie Clef. Pregătirea și generarea s-au făcut local; antrenarea și evaluarea, în Google Colab pe Tesla T4.

Corpusul principal conține 3.767 de texte presupuse umane și 2.590 de texte AI. Articolele umane provin din arhiva UNIMEDIA, din intervalul 1 octombrie - 17 decembrie 2018. Proveniența istorică este un indiciu de autorie umană, nu o certificare independentă.

Datele au fost împărțite în 4.448 exemple de antrenare, 955 de calibrare și 954 de test. Gruparea pe surse și similarități lexicale cunoscute reduce suprapunerea între partiții, dar nu exclude toate evenimentele comune. Au fost păstrate textele selectate ne-goale, inclusiv răspunsurile AI scurte sau slabe; nu s-a echilibrat corpusul prin eliminări.

2. Generarea textelor AI

Prompturile folosesc tema generală, nume și alte detalii extrase prin reguli, data de referință și lungimea dorită. Nu includ corpul sau titlul original și nici un rezumat cu faptele esențiale. Promptul de sistem cere o știre în română și permite un eveniment fictiv plauzibil. Perechile human/AI nu au, deci, fapte identice garantate.

Generator	Texte AI incluse	Servire
Qwen3.5 0.8B	861	Ollama
Qwen3.5 2B	547	Ollama
Qwen3.5 4B	213	Ollama
Gemma 3 270M	150	Ollama
Gemma 3 1B	219	Ollama
Qwen2.5 0.5B	200	llama.cpp
Qwen2.5 1.5B	200	llama.cpp
Qwen2.5 3B	200	llama.cpp

3. Antrenare și calibrare

Configurația principală: cuantizare 4-bit, LoRA rank 16 și alpha 16, o epocă, learning rate 0,0002, batch 1, acumulare pe 16 pași și seed 3407. Antrenarea are 278 de pași. După întreruperea sesiunii, rularea a fost reluată din checkpointul 160 și a ajuns la epoca 1.

Contextul este de 12.288 de tokeni; cea mai lungă intrare formatată are 10.465 de tokeni. Nu s-au trunchiat articole. Pe T4, calea GQA nativă nu era compatibilă cu forma atenției. Remediul restrâns folosește replicarea explicită K/V din Transformers și atenția eficientă; nu schimbă textele sau greutățile modelului de bază. Testele pilot au verificat forward/backward și operatorii utilizați.

Calibrarea s-a făcut separat pe cele 955 de exemple dedicate. Pragul de decizie a rămas 0,5 și nu a fost reglat pe test. Modelul calibrat și predicțiile au fost salvate înainte de analiza erorilor.

4. Rezultatele testului principal

Modelul a clasificat corect 952 din 954 de texte: acuratețe 99,79%. Din 565 de texte human, unul a fost marcat AI (FPR 0,177%). Din 389 de texte AI, unul a fost marcat human (recall AI 99,74%).

Model-sursă	AI detectate	Recall AI	FPR human pereche
Gemma3-1B	33/33	100.00%	0.00%
Gemma3-270M	24/24	100.00%	0.00%
Qwen2.5-0.5B	30/30	100.00%	0.00%
Qwen2.5-1.5B	30/30	100.00%	0.00%
Qwen2.5-3B	29/30	96.67%	0.00%
Qwen3.5-0.8B	129/129	100.00%	0.00%
Qwen3.5-2B	80/80	100.00%	0.00%
Qwen3.5-4B	33/33	100.00%	0.00%

Rezultatele per model folosesc textele AI și sursele umane pereche din test. Falsul pozitiv global nu apare în aceste subseturi pereche; FPR per model este astfel zero, deși FPR global este nenul. Subseturile pot reutiliza surse, deci nu se însumează.

Qwen2.5 3B este singurul generator cu un exemplu AI nedetectat (29/30). Eșantionul mic nu permite concluzia că este sistematic cel mai greu de prins. Falsul pozitiv este o agendă administrativă de 100 de cuvinte, diferită ca structură de o știre narativă. Nu s-a demonstrat cauza internă a niciuneia dintre erori.

5. Experiment suplimentar: sampling variat

Pentru a compara profiluri de sampling prin Ollama, am folosit 30 de surse noi față de corpusul înghețat, Qwen2.5 1.5B și 3B și două profiluri. Profilul conservator are temperature=0,3 și top_p=0,8; cel variat, temperature=0,9 și top_p=0,95. Ambele au top_k=20. Au rezultat 120 de texte AI, câte 30 pentru fiecare condiție, plus 30 de controale human.

Model	Profil	AI detectate	Human corecte
Qwen2.5 1.5B	conservator	30/30	30/30
Qwen2.5 1.5B	variat	30/30	30/30
Qwen2.5 3B	conservator	30/30	30/30
Qwen2.5 3B	variat	30/30	30/30

Toate cele 150 de texte au fost clasificate corect. Nu au apărut perechi discordante între profiluri (McNemar exact p=1); aceasta nu demonstrează echivalența profilurilor. Cele 30 de surse sunt comune celor patru condiții, nu există 120 de surse independente. Controalele au 81-99 de cuvinte, iar promptul AI cere minimum 100, ceea ce poate oferi un indiciu de lungime. Zero false pozitive din 30 are un interval Wilson 95% de 0-11,35%.

6. Calibrare și limite

Pe testul principal, toate probabilitățile salvate sunt exact 0 sau 1, inclusiv pentru cele două erori. Brier și ECE sunt aproximativ 0,00210. Pe lotul suplimentar fără erori, acești indicatori sunt zero. Rezultatele nu justifică interpretarea probabilităților ca încredere individuală perfect calibrată pentru texte noi.

Textele human provin dintr-o singură publicație și perioadă, iar modelele generatoare sunt reprezentate și la antrenare. Textele AI pot conține repetiții sau probleme de limbă, pe care detectorul le poate exploata. Nu au fost evaluate familii complet necunoscute, alte publicații sau texte AI revizuite uman. Scorurile celor două experimente se raportează separat; nu au fost folosite pentru reajustarea detectorului.

7. Concluzie

Fluxul Unsloth a putut fi adaptat pentru clasificarea știrilor în română și rulat pe T4 fără trunchiere. Separarea corpusului construit este aproape completă, dar nu reprezintă o metodă universală de stabilire a autoriei. Setul de generare, notebookul și rezultatele salvate permit examinarea configurației și a experimentelor.

Referințe

Unsloth, Train your own Decision Model with Unsloth:
https://unsloth.ai/docs/basics/train-your-own-decision-model-with-unsloth
Notebookul de referință: https://github.com/unslothai/notebooks
Arhiva UNIMEDIA: https://unimedia.info
Datele numerice provin din predicțiile și configurațiile salvate ale proiectului.